

ago 25, 2026

Procesamiento del Lenguaje Natural II (1/8) - b041b26

Invitado abraham.rodz17@gmail.com

Procesamiento del Lenguaje Natural II - MIA 4Co2026 malemehaute@gmail.com

flor.p.vela@gmail.com alejandrozevallos.218@gmail.com

biancardiagustin123@gmail.com andreannarattone@gmail.com

jsbonals@gmail.com aferenaz@gmail.com

Archivos adjuntos  Procesamiento del Lenguaje Natural II (1/8) - b041b26

Registros de la reunión  Transcripción  Grabación

Resumen

La sesión cubrió la introducción a la materia, la arquitectura de Transformers y la evaluación de modelos.

Introducción y logística académica

Se presentaron los objetivos de la materia y el esquema de evaluación basado en 2 trabajos prácticos individuales. Se ajustó el contenido programático para incluir temas avanzados sobre agentes.

Arquitectura técnica del Transformer

Se analizó la arquitectura del Transformer mediante el mecanismo de atención, estableciendo su superioridad frente a arquitecturas recurrentes previas. Se determinó la importancia crítica del tokenizador en la eficiencia computacional de los modelos de lenguaje.

Arquitecturas avanzadas y recursos

Se explicó la aplicación de la arquitectura Transformer en modelos de visión artificial. Se definieron las fuentes académicas principales para el seguimiento de nuevas investigaciones científicas.

Próximos pasos

- ☐ [Ise posgrados] Actualizar presentación: Subir la presentación de la clase actual ligeramente actualizada al repositorio.
- ☐ [Ise posgrados] Publicar TP1: Finalizar la redacción del primer trabajo práctico y subirlo al repositorio.
- ☐ [Ise posgrados] Actualizar reglas TP: Incluir la nota sobre el carácter individual de los trabajos prácticos en la presentación.
- ☐ [Ise posgrados] Compartir papers: Enviar los artículos sobre técnicas de predicción usando modelos Transformer a los estudiantes interesados.
- ☐ [Andrea Ferenaz] Compartir recursos: Proporcionar información sobre la plataforma y el proyecto de IA aplicado a servicios energéticos.
- ☐ [El grupo] Leer paper Attention: Leer y digerir el artículo de investigación original Attention Is All You Need para comprender la arquitectura de Transformer y los mecanismos de atención antes de la segunda clase.
- ☐ [El grupo] Leer An Transformer: Estudiar el recurso de implementación de Python denominado An Transformer para analizar la estructura del codificador y decodificador previo a la siguiente lección.
- ☐ [Ise posgrados] Actualizar diapositivas: Actualizar el material de presentación utilizado en clase. Subir el archivo actualizado al repositorio de la materia.
- ☐ [Ise posgrados] Compartir enlace de traducción: Buscar y compartir el repositorio que realiza la traducción de idiomas durante la inferencia en modelos de lenguaje.
- ☐ [El grupo] Implementar Tiny GPT: Desarrollar el proyecto Tiny GPT como parte de la tarea TP1. Reutilizar un tokenizer preentrenado para realizar pruebas de compatibilidad.
- ☐ [El grupo] Leer artículo tokenizadores: Leer el artículo recomendado sobre las limitaciones y los peligros de reutilizar los tokenizadores de Llama para profundizar en el tema.
- ☐ [El grupo] Ejecutar trabajo práctico: Aplicar las técnicas de cuantización y utilizar cargadores de datos optimizados durante el desarrollo del trabajo práctico.

- ☐ [El grupo] Evaluar modelo: Realizar la evaluación del modelo mediante benchmarks específicos según la tarea asignada al transformador.
- ☐ [El grupo] Exportar modelo: Exportar el modelo resultante a un formato eficiente compatible con Hugging Face para finalizar el trabajo práctico.

Detalles

- **Presentación del docente (Ise posgrados):** El instructor, Abraham Rodríguez, dio la bienvenida a la asignatura de Procesamiento de Lenguaje Natural 2, mencionando su trayectoria previa en Inteligencia Artificial embebida y su especialización actual en servidores de inferencia, chatbots y sistemas RAG ([00:00:35](#)). El docente comentó que cuenta con experiencia profesional como arquitecto de IA en el sector hotelero y como líder técnico en desarrollo backend, y aclaró que esta materia ha sido impartida durante los últimos dos años ([00:05:44](#)).
- **Presentación de los estudiantes:** La sesión incluyó una ronda de presentaciones donde cada estudiante detalló su perfil profesional y académico. Alejandro Muñoz, Ingeniero Mecatrónico de Perú, destacó su rol como Machine Learning Engineer en Interseguro trabajando con MLOps y Google Cloud ([00:07:35](#)). Anahi Bazet, Ingeniera Informática y docente, mencionó su interés en seguir explorando el procesamiento de lenguaje natural para su proyecto de maestría ([00:09:27](#)). Andrea Annarattone, proveniente del área de salud, busca aplicar machine learning en neurología ([00:11:01](#)). Andrea Ferenaz, especialista en IA, trabaja con agentes para una empresa de servicios medioambientales, utilizando plataformas como Veolia Chat ([00:13:34](#)). Belén Cattaneo, Ingeniera Mecánica, se desempeña en el ámbito de marketing digital, aplicando modelos de forecasting ([00:16:23](#)). Daniel Peñaranda, científico de datos, detalló su experiencia utilizando OCR y servicios cognitivos de Azure para la digitalización de documentos ([00:17:46](#)). Fermín Rodríguez, docente universitario, indicó su interés en materias como investigación operativa y gestión de datos ([00:20:31](#)). Florencia Vela, Ingeniera Informática, trabaja en ciberseguridad, desarrollando modelos para la detección de comportamientos maliciosos en usuarios ([00:21:49](#)). Gerardo Breard, economista, explicó su trabajo en análisis semántico de habilidades laborales mediante el uso de grafos y ontologías ([00:24:37](#)). Martín González, ingeniero electrónico, compartió su proyecto actual sobre la desagregación de cargas eléctricas para monitoreo

de consumo en hogares mediante IoT ([00:27:37](#)). Melina Lazzaro mencionó cursar la diplomatura por interés personal ([00:32:42](#)). Natalia Díaz, ingeniera electrónica, comentó su participación en proyectos ferroviarios y el uso de herramientas de Microsoft para análisis de datos ([00:33:46](#)). Sebastián Bonals, economista y científico de datos en Equifax, detalló su labor en modelos de riesgo crediticio y su interés académico en forecasting ([00:37:23](#)).

- **Actualización del programa de la materia:** Ise posgrados informó que el contenido del repositorio de la materia será actualizado, ya que se han realizado ajustes al plan de estudios, incluyendo temas como agentes y sus aplicaciones, que se ven en la materia de procesamiento de lenguaje natural 3 ([00:41:07](#)). Se adelantó que la materia es tentativa debido a la posible participación de un profesor invitado hacia la clase 5 para abordar reinforcement learning ([00:42:43](#)).
- **Temario y contenidos de la asignatura:** Se presentó un esquema de contenidos que abarca: el repaso de Transformers y tokenización, arquitectura de modelos de lenguaje (LLMs), técnicas de escalamiento como Mixture of Experts (MoE), evaluación de modelos, uso de APIs, inferencia en modelos locales, bases de datos vectoriales, el patrón RAG (Retrieval-Augmented Generation), introducción a agentes, modelos de razonamiento y multimodalidad ([00:42:43](#)). Se señaló que PyTorch será el framework principal, complementado con el ecosistema de Hugging Face, Chroma y Jupiter Notebooks ([00:45:53](#)).
- **Evaluación y trabajos prácticos:** La evaluación consiste en dos trabajos prácticos (TP). El TP1 se divide en el preentrenamiento de un modelo pequeño de lenguaje (LLM) de tipo denso y la implementación de un modelo tipo MoE. El TP2 requiere realizar el fine-tuning del modelo preentrenado. Los trabajos son de carácter individual y se deben entregar antes de la clase 7 y clase 8 ([00:47:05](#)). El docente aseguró que los modelos pueden ejecutarse en entornos como Google Colab y que no se requiere hardware de gran escala para completar los ejercicios, ya que el objetivo es comprender el concepto técnico ([00:50:04](#)).
- **Logística de descansos:** Se realizó una encuesta entre los estudiantes para definir la estructura de los recreos durante la clase, ofreciendo las opciones de un descanso de 20 minutos o dos descansos de 10 minutos ([00:51:33](#)).
- **Evolución y benchmarks de modelos de lenguaje:** Ise posgrados expuso la historia de la evolución de los modelos de lenguaje, señalando que anteriormente la métrica principal era el número de parámetros (como en los

casos de Bert, GPT-2 y GPT-3). Actualmente, el enfoque ha cambiado hacia benchmarks como MMLU (Massive Multitask Language Understanding), donde modelos de menor tamaño pueden igualar el rendimiento de modelos mucho más grandes, demostrando que el tamaño de los parámetros ya no es el único factor relevante ([00:51:33](#)).

- **Introducción a la arquitectura Transformer:** Se presentó el paper "Attention Is All You Need" (2017) como el fundamento técnico de la asignatura. El docente destacó que la innovación clave introducida es el mecanismo de atención, el cual permite al modelo correlacionar secuencias de texto de manera dinámica y eficiente, superando las limitaciones de memoria y la naturaleza secuencial de arquitecturas anteriores como las redes recurrentes o las redes LSTM ([00:54:47](#)).
- **Limitaciones de las Redes Neuronales Recurrentes:** LSE Posgrados señala que los modelos de memoria a corto y largo plazo (LSTM) presentan dificultades, ya que su naturaleza secuencial resulta lenta para el entrenamiento y sufren de problemas de desvanecimiento de memoria ([00:59:34](#)).
- **Introducción a la arquitectura Transformer:** LSE Posgrados explica que el mecanismo de atención del Transformer busca solucionar las limitaciones de las redes recurrentes, permitiendo procesar secuencias en paralelo de forma independiente y globalizada en lugar de seguir un orden estrictamente secuencial ([00:59:34](#)).
- **Matrices de atención y correlación:** El ponente describe la matriz de atención como una herramienta de correlación que permite al modelo asociar palabras entre diferentes lenguajes, como del francés al inglés, estableciendo relaciones contextuales entre los tokens de la secuencia ([01:01:09](#)).
- **Embeddings en el Transformer:** LSE Posgrados detalla que el proceso comienza con la conversión de tokens de texto en embeddings, los cuales habitan un espacio latente que permite al modelo representar conceptos vectorial y agruparlos en clústeres, como la distinción entre seres vivos y objetos inanimados ([01:02:46](#)).
- **Codificación posicional:** Dado que el Transformer no utiliza recurrencia ni convolución, LSE Posgrados explica que es necesario inyectar información sobre el orden de los tokens mediante la codificación posicional ([01:05:59](#)). Este proceso puede realizarse mediante parámetros aprendidos o funciones

senoidales fijas que consideran un número base de 10,000 para representar la posición relativa o absoluta dentro de la secuencia ([01:08:00](#)).

- **Normalización de capas:** LSE Posgrados indica que la normalización de capas (Layer Norm) es un componente fundamental dentro de la arquitectura que cumple la función de estabilizar el aprendizaje y optimizar la convergencia durante el entrenamiento ([01:13:01](#)).
- **Redes Feed Forward:** El ponente describe la capa Feed Forward como una red lineal estándar que permite al modelo identificar características complejas mediante la introducción de no linealidad, siendo el bloque estándar una profundidad de dos capas ([01:14:41](#)).
- **Investigación en arquitecturas Feed Forward:** LSE Posgrados menciona que existen diversas investigaciones actuales enfocadas en optimizar las capas Feed Forward, explorando variantes como el aumento de profundidad o anchura, los modelos de "Fast Feed Forward" y la "Mezcla de Expertos" (Mixture of Experts), buscando mejoras marginales en cómputo y rendimiento ([01:16:31](#)).
- **Recursos de implementación del Transformer:** LSE Posgrados recomienda la lectura del recurso "Annotated Transformer", el cual ofrece una implementación manual en Python de los componentes del modelo, incluyendo el codificador, el decodificador y los mecanismos de atención, sin depender de librerías externas para los bloques fundamentales ([01:19:40](#)).
- **Mecanismo de atención escalada:** El ponente explica el mecanismo de "Scaled Dot-Product Attention", el cual calcula la atención utilizando tres matrices fundamentales: Consultas (Queries), Llaves (Keys) y Valores (Values), aplicando multiplicaciones matriciales, escalamiento y la función Softmax para obtener la matriz de contexto ([01:25:50](#)).
- **Atención de múltiples cabezales:** LSE Posgrados describe la atención de múltiples cabezales (Multi-Head Attention) como el proceso de ejecutar varias capas de atención en paralelo, cuyos resultados se concatenan y proyectan a la dimensión original ([01:50:58](#)). Este proceso es computacionalmente costoso, con una complejidad temporal de $O(N \text{ al cuadrado})$ debido a las multiplicaciones matriciales ([01:52:35](#)).
- **Procesamiento de entrada y ventana de contexto:** LSE Posgrados detalla que la entrada al Transformer surge de los embeddings, los cuales se utilizan para generar las matrices de consultas, llaves y valores ([01:54:08](#)). El ponente subraya que la longitud de esta secuencia de entrada es un parámetro crítico

en los Grandes Modelos de Lenguaje (LLM), conocido comúnmente como ventana de contexto o "context length" ([01:56:54](#)).

- **Mecanismo de atención y normalización:** Ise posgrados explica que el tamaño de la matriz de atención influye en la capacidad de los modelos para soportar millones o trillones de tokens en un solo llamado de API. Se describe el proceso de escalamiento y el uso de Softmax dentro del mecanismo de atención para estabilizar el entrenamiento, evitando valores sesgados o excesivamente grandes, y normalizando los resultados en un rango de 0 a 1 ([01:58:24](#)).
- **Overview del paper "Attention is all you need":** Ise posgrados presenta una visión general del paper fundacional, destacando la arquitectura Encoder-Decoder utilizada para tareas como la traducción automática y el funcionamiento del self-attention ([02:00:04](#)).
- **Visualización de la atención con BERT:** Se introduce el uso de herramientas como BERT viz para visualizar matrices de atención y observar la autocorrelación entre palabras en inglés, identificando cómo las distintas capas y cabezales (heads) priorizan tokens especiales como el SEP ([02:01:20](#)).
- **Arquitectura secuencial del Transformer:** Ise posgrados detalla que los bloques del Transformer, denotados como NX, se iteran secuencialmente. Se enfatiza que, a diferencia del multi-head attention, el procesamiento de estos bloques es secuencial: el output de un bloque sirve como input para el siguiente ([02:02:50](#)).
- **Granularidad en capas y cabezales:** Al profundizar en las capas del Transformer, Ise posgrados explica que se identifican características más granulares, lo cual conlleva un mayor costo computacional. Se aclara la relación entre la dimensión de los cabezales (heads) del multi-head attention y los bloques del Transformer ([02:04:37](#)).
- **Desafíos computacionales en Multi-head attention:** Se identifica al multi-head attention como una de las capas más investigadas y problemáticas debido a que representa un cuello de botella computacional en los modelos de lenguaje (LLM). Ise posgrados explica que la traducción no es un problema uno a uno, sino contextual, requiriendo correlacionar toda la secuencia ([02:06:07](#)).
- **Autocorrelación vs. Cross-attention:** Ise posgrados pregunta sobre el tipo de correlación que ocurre en los bloques del encoder y decoder ([02:09:07](#)). Sebastián Bonals confirma que es una autocorrelación (self-attention),

donde la entrada es la misma ([02:10:21](#)). Ise posgrados explica que el cross-attention, que conecta el encoder con el decoder, es el mecanismo donde el espacio latente del idioma original se correlaciona con el idioma objetivo, aunque este bloque se elimina en las arquitecturas GPT que son solo decoder ([02:11:28](#)).

- **Tipos de atención y eficiencia:** Se mencionan variantes de atención como la global y local, y la importancia de la atención lineal para reducir la complejidad cuadrática del Transformer vanilla ([02:13:08](#)).
- **Predicción de tokens y probabilidad:** Ise posgrados describe el funcionamiento de los LLM como máquinas de probabilidad de token IDs ([02:17:16](#)). Se explica que el modelo toma una secuencia de entrada (tokenizada), la propaga a través de n bloques de Transformer, y la capa final de Softmax genera una distribución de probabilidad para predecir el siguiente token ([02:15:54](#)).
- **Definición e importancia del Tokenizer:** Ise posgrados define el tokenizer como un proceso de descomposición de texto fundamental para representar información de manera compacta y crear el espacio vectorial de embeddings. Se resalta que, aunque a menudo es un paso ignorado, es crucial para el desempeño del modelo ([02:21:40](#)).
- **Compatibilidad de tokenizadores entre modelos:** Se comparan tokenizadores de modelos como GPT-4o, Gemma y Llama, demostrando que cada modelo tiene su propio vocabulario y conteo de tokens, lo que hace que sus tokenizadores sean incompatibles entre sí ([02:23:18](#)).
- **Debate sobre eficiencia multilingüe:** Anahi Bazet pregunta sobre la eficiencia de usar inglés frente a otros idiomas y si conviene traducir antes de tokenizar ([02:29:08](#)). Ise posgrados aclara que la eficiencia depende del corpus de entrenamiento y confirma que idiomas como el mandarín pueden comprimir mejor el significado que el inglés, lo cual resulta en una mayor eficiencia computacional durante la inferencia ([02:30:27](#)). Se concluye que realizar traducciones intermedias durante la inferencia suele ser contraproducente debido al costo de procesos adicionales ([02:31:38](#)).
- **Algoritmo Byte Pair Encoding (BPE):** Ise posgrados explica el funcionamiento de BPE, un proceso iterativo basado en frecuencia que identifica los pares de bytes más comunes en un corpus y los fusiona en nuevos tokens para comprimir la secuencia de texto ([02:32:51](#)).
- **Limitaciones y reutilización de Tokenizers:** Se discute que el entrenamiento de tokenizadores es computacionalmente costoso y difícil de

optimizar, por lo que es práctica común reutilizar tokenizadores preentrenados (como en el caso de DeepSeek o Gemma) en lugar de crear uno nuevo desde cero ([02:38:53](#)).

- **Implementación técnica de tokenizadores:** Ise posgrados señala que, debido a la complejidad de algoritmos como BPE, lenguajes como Rust y Go son preferidos sobre Python para la implementación de tokenizadores de producción debido a su mayor eficiencia ([02:43:28](#)). Se menciona la librería Tiktoken de OpenAI como un ejemplo de optimización ([02:44:55](#)) ([02:48:18](#)).
- **Riesgos de reciclar tokenizadores:** Se advierte que reutilizar tokenizadores de otros modelos (como el de Llama) puede limitar la capacidad del modelo para adaptarse a dominios especializados y puede heredar reglas de pretokenización no deseadas, como el agrupamiento de cifras numéricas en Llama 3.1 ([02:49:44](#)).
- **Optimización de Transformers:** Se listan técnicas de optimización relevantes para el proyecto de la materia (TP), incluyendo la cuantización, el uso de Flash Attention para la inferencia, y el uso de técnicas como LoRA para el fine-tuning ([02:54:03](#)).
- **Diferencia entre LLM y Chatbot:** Ise posgrados enfatiza que un GPT preentrenado no es un chatbot, sino un modelo de completado de texto. La capacidad de respuesta a preguntas requiere un proceso posterior de fine-tuning. Se concluye mencionando que la arquitectura Transformer es versátil y aplicable más allá del procesamiento de lenguaje natural, extendiéndose a la visión artificial y el análisis de series de tiempo ([02:56:41](#)).
- **Arquitectura Vision Transformer:** `Ise posgrados` indicó que, en el modelo Vision Transformer, el Transformer Encoder mantiene una estructura consistente similar a otras aplicaciones, donde el único factor de diferencia reside en las secuencias de entrada y el procesamiento de los embeddings iniciales del modelo ([02:57:54](#)).
- **Recursos de investigación científica:** `Ise posgrados` recomendó diversas plataformas para la búsqueda y seguimiento de artículos académicos, sugiriendo el uso de Hugging Face Daily Papers, el repositorio arXiv como la fuente principal de publicaciones, y los índices de investigación de empresas como Facebook Research ([02:57:54](#)).
- **Planificación de la próxima sesión y cierre:** Tras verificar que no hubiera más preguntas, `Ise posgrados` confirmó que el tema a tratar en la reunión de la siguiente semana serán los modelos de lenguaje (LLM), finalizando el

encuentro con las despedidas de `Sebastián Bonals`, `Belén Cattaneo`,
`Anahi Bazet`, `Martin Gonzalez` y `Ise posgrados` ([02:57:54](#)).

Revisa las notas de Gemini para asegurarte de que sean precisas. [Obtén sugerencias y descubre cómo Gemini toma notas](#)

*Cómo es la calidad de **estas notas específicas**? [Responde una breve encuesta](#) para darnos tu opinión; por ejemplo, cuán útiles te resultaron las notas.*