

sept 1, 2026

Procesamiento del Lenguaje Natural II (2/8) - b041b26

Invitado abraham.rodz17@gmail.com

Procesamiento del Lenguaje Natural II - MIA 4Co2026

Archivos adjuntos  Procesamiento del Lenguaje Natural II (2/8) - b041b26

Registros de la reunión  Transcripción  Grabación

Resumen

La sesión analizó la evolución técnica de los modelos Transformer desde GPT hasta arquitecturas modernas con escalabilidad.

Arquitectura y evolución fundamental

El estudio repasó la transición de la arquitectura Transformer Decoder básica hacia modelos escalados, enfatizando el entrenamiento causal, el preentrenamiento y la relevancia de los mecanismos de atención. Se definió la importancia de las leyes de escalamiento y el impacto de los datos en la capacidad de generalización.

InstructGPT y optimización moderna

Se detalló el flujo de entrenamiento de InstructGPT mediante ajuste fino supervisado y aprendizaje por refuerzo con retroalimentación humana para mitigar alucinaciones. Este enfoque se ha consolidado como el estándar actual en el desarrollo de arquitecturas contemporáneas como Llama y Mistral.

Implementación práctica y optimización

La sesión estableció los lineamientos para el desarrollo del primer trabajo práctico enfocado en la creación de un modelo Tiny GPT. Se definieron técnicas clave para optimizar la inferencia, como el caché de claves y valores y el uso de Mixture of Experts.

Próximos pasos

- ☐ [El grupo] Implementar muestreo: Codificar el algoritmo de muestreo para el Trabajo Práctico 1 según lo solicitado.
- ☐ [El grupo] Preparar Trabajo Práctico: Preparar el corpus, realizar la tokenización y construir la arquitectura del modelo para el Trabajo Práctico 1.
- ☐ [Ise posgrados] Compartir recurso: Compartir con la estudiante la información sobre la medición de toxicidad y la muestra del conjunto de datos para profundizar en el tema.
- ☐ [El grupo] Preentrenar modelo GPT: Preentrenar un modelo transformer de tipo GPT utilizando la arquitectura y los helpers provistos en el código.
- ☐ [El grupo] Implementar algoritmos decodificación: Implementar y comparar estrategias de decodificación incluyendo greedy, temperatura, Top K y Top P.
- ☐ [El grupo] Implementar caché KV: Integrar la técnica de caché KV y evaluar su impacto en la velocidad de inferencia.
- ☐ [El grupo] Implementar Mixture of Experts: Desarrollar la variante de arquitectura Mixture of Experts con enrutamiento Top K y comparar el rendimiento frente al modelo denso.
- ☐ [El grupo] Enviar repositorio: Enviar el enlace del repositorio de GitHub con el proyecto final al profesor por correo electrónico.
- ☐ [Ise posgrados] Compartir material: Subir el contenido de la clase anterior a un nuevo branch y enviar un correo electrónico informando sobre la disponibilidad del material.

Detalles

- **Introducción y logística del curso:** *Ise posgrados* da inicio a la sesión, saludando al grupo y confirmando la presentación del primer Trabajo Práctico (TP), cuya realización depende de los contenidos abordados en esta y la siguiente clase ([00:00:44](#)).
- **Fundamentos de los Large Language Models y el Transformer Decoder:** Se explica que los Grandes Modelos de Lenguaje (LLMs) y la mayoría de los modelos generativos actuales se basan en la arquitectura del Transformer

Decoder. Esta estructura elimina el codificador y el mecanismo de atención cruzada (cross-attention) del modelo Transformer original, resultando en una capa simplificada con atención de múltiples cabezas (multi-head attention) y una red neuronal hacia adelante (feed-forward) ([00:06:17](#)).

- **El papel del espacio latente en la generación:** *Ise posgrados* detalla que el decodificador trabaja sobre un espacio latente de información, el cual contiene características semánticas de los datos proporcionadas por las incrustaciones (embeddings). La labor principal del modelo es utilizar esta información para completar secuencias de texto, una arquitectura que define a modelos como GPT, ChatGPT, Llama, Mistral, Gemma, DeepSeek, y modelos multimodales como CLIP e Image GPT ([00:08:03](#)).
- **Concepto de preentrenamiento generativo (GPT-1):** Se introduce el paper de GPT-1 de OpenAI, que emplea la arquitectura del Transformer Decoder con modificaciones menores. El proceso incluye una capa de entrada para texto y posiciones, una etapa de atención de múltiples cabezas y una capa lineal final utilizada para tareas específicas como clasificación o medición de similitud ([00:12:23](#)).
- **Objetivo matemático del modelo:** El preentrenamiento se define como el modelado estándar del lenguaje de tipo causal, donde el objetivo es maximizar la verosimilitud de la probabilidad del token actual dada la secuencia de tokens anteriores. El parámetro K representa el tamaño de la ventana de contexto, cualidad que permite a los modelos actuales procesar hasta un millón de tokens en un solo paso hacia adelante (forward) ([00:15:16](#)).
- **Flujo de trabajo de la arquitectura:** El proceso comienza con el ingreso de la secuencia de tokens multiplicada por la matriz de incrustaciones más las incrustaciones posicionales. Estos datos pasan por 12 bloques de Transformer consecutivos de manera secuencial, cuya salida se multiplica por la matriz de incrustaciones y se aplica la función Softmax para obtener la distribución de probabilidad de los tokens de salida ([00:18:39](#)).
- **Demostración de generación y muestreo:** *Ise posgrados* realiza una demostración local de GPT-2, mostrando cómo el modelo toma una secuencia de entrada tokenizada y genera una distribución de probabilidad para la siguiente palabra. Se menciona que el token más probable no siempre es el correcto, por lo que se emplean algoritmos de muestreo para determinar la salida final ([00:21:49](#)).
- **Especificaciones técnicas de GPT-1:** Se describen las características de la primera arquitectura: 12 capas de bloques de Transformer, 768 dimensiones

de espacio de incrustación, 12 cabezas de atención, una red feed-forward estándar, el uso de Byte Pair Encoding con 40,000 iteraciones y un corpus de entrenamiento ligero de unos pocos gigabytes de libros ([00:25:10](#)).

- **Mecanismo de causalidad mediante enmascaramiento:** Para garantizar la causalidad, el Transformer utiliza una máscara en la matriz de atención, representada por una matriz triangular que impide que el modelo vea tokens futuros durante el entrenamiento. Se menciona también la variante de atención lineal con ventana deslizante (sliding window), que resulta eficiente para gestionar contextos extensos ([00:26:42](#)).
- **Implementación práctica del Trabajo Práctico:** *Ise posgrados* indica que el TP involucra la preparación de un corpus, la tokenización y la construcción de la arquitectura del modelo, enfocándose en el preentrenamiento causal y la aplicación de la función de pérdida para obtener un modelo fundacional ([00:29:45](#)).
- **Resultados de la generación causal:** Se ejemplifica cómo el modelo completa secuencias basándose en el historial del contexto. Si se modifica la entrada o se elimina el espacio, el modelo pierde el hilo de la secuencia original, demostrando la dependencia del historial provisto ([00:32:58](#)).
- **Metodología de Supervised Fine-Tuning:** Tras el preentrenamiento, se puede realizar un ajuste fino supervisado (Supervised Fine-Tuning). Esto implica utilizar un conjunto de datos etiquetado y agregar una capa lineal al modelo preentrenado para predecir la etiqueta, maximizando la verosimilitud de dicha etiqueta dada la secuencia de entrada ([00:34:20](#)).
- **Rutas de entrenamiento:** Se distinguen tres enfoques principales: el preentrenamiento fundacional con grandes corpus, el ajuste fino (Fine-Tuning) para dominios específicos como medicina, y el aprendizaje en contexto (In-context learning) que utiliza instrucciones (prompting) sin necesidad de reajustar los pesos del modelo ([00:37:23](#)).
- **Evolución con GPT-2:** Presentado en 2019, GPT-2 reutilizó la arquitectura de GPT-1 pero escaló significativamente el dataset a 45 gigabytes de contenido diverso de la web y aumentó los parámetros a 1.5 billones, duplicando también la ventana de contexto a 1024 tokens ([00:40:37](#)).
- **Descubrimiento de capacidades Zero-Shot:** Gracias al escalamiento de GPT-2, se descubrió la capacidad de realizar tareas para las cuales el modelo no fue entrenado explícitamente, fenómeno conocido como Zero-Shot learning, lo que mejoró notablemente la coherencia y longitud del texto generado ([00:42:17](#)).

- **Introducción a GPT-3 y Sparse Transformer:** En 2020, GPT-3 introdujo un cambio arquitectónico relevante al sustituir el mecanismo de atención tradicional por el Sparse Transformer, optimizando la complejidad computacional. El modelo más grande, llamado DaVinci, alcanzó los 175 billones de parámetros ([00:45:13](#)).
- **Hipótesis y costos de GPT-3:** GPT-3 buscó comprobar que el escalamiento de parámetros mejora el rendimiento en múltiples tareas sin necesidad de Fine-Tuning. Fue un modelo computacionalmente costoso, utilizando miles de petaflops por día durante el entrenamiento, y se entrenó con 410 billones de tokens provenientes de Common Crawl, Wikipedia y libros ([00:46:54](#)).
- **Recursos de cómputo para entrenamiento:** *Ise posgrados* menciona a Lambda Labs como proveedor de cómputo acelerado. Se estima que, con la tecnología de la época y utilizando las unidades de procesamiento gráfico (GPU) más económicas, el costo de entrenar un modelo como GPT-3 habría sido de aproximadamente 4.6 millones de dólares ([00:49:50](#)).
- **Técnicas de prompting: Zero, One y Few-Shot:** GPT-3 popularizó el uso de Zero-Shot (sin ejemplos), One-Shot (un ejemplo) y Few-Shot (varios ejemplos) como técnicas de prompting para realizar tareas sin actualizar gradientes, consolidando el campo de la ingeniería de prompts (prompt engineering) ([00:53:20](#)).
- **Ventaja de los modelos generalistas:** La flexibilidad de GPT-3 radica en actuar como un modelo universal capaz de realizar diversas tareas sobre la marcha, evitando la ineficiencia de crear modelos especializados mediante Fine-Tuning para cada labor particular ([00:56:19](#)).
- **Importancia de la diversidad de los datos:** La capacidad de generalización de GPT-3 se atribuye a la diversidad del conjunto de datos de entrenamiento, que abarca múltiples formatos como foros, prosa literaria y textos informativos, permitiendo al modelo aprender patrones, idiomas y formatos diversos simultáneamente ([00:57:50](#)).
- **Escalabilidad y Aprendizaje de GPT-3:** Ise posgrados explica que la capacidad de generalización en modelos como GPT-3 depende de escalar el número de parámetros. Se discute el concepto de "in-context learning" y se muestra cómo, mediante técnicas como "few-shot prompting", los modelos mejoran su precisión en tareas específicas. Se mencionan recursos como la "Prompt Engineering Guide" para explorar técnicas de ingeniería de prompts, incluyendo "ReAct" y "Chain-of-Thought".

- **Leyes de Escalamiento y Limitaciones de Rendimiento:** Se analiza un documento de investigación de OpenAI sobre las leyes de escalamiento de los modelos de lenguaje, el cual discute cómo la función de pérdida encuentra un límite asintótico respecto al cómputo, lo que indica que el escalamiento de parámetros no es infinito. Se utiliza el conjunto de datos TriviaQA para demostrar que los modelos generalistas, al utilizar las instrucciones adecuadas, pueden equipararse o superar a los modelos especialistas.
- **Limitaciones de GPT-3 y el Surgimiento de InstructGPT:** Ise posgrados señala que GPT-3 presentaba problemas significativos, incluyendo la generación de contenido tóxico, alucinaciones y respuestas inútiles para los usuarios. En 2022, OpenAI introdujo InstructGPT para corregir estas deficiencias mediante un ajuste fino. Un punto clave destacado es que una versión más pequeña de InstructGPT, con 1.3 mil millones de parámetros, superó en desempeño a modelos de GPT-3 significativamente más grandes.
- **Medición de la Toxicidad en Modelos de Lenguaje:** Ante la consulta de Anahi Bazet sobre cómo se mide la toxicidad, Ise posgrados explica que se emplean conjuntos de datos etiquetados y benchmarks. Se introduce la técnica de "LLM-as-a-judge", donde un modelo más avanzado evalúa las salidas de otro modelo basándose en umbrales predefinidos, un tema que se explorará con mayor profundidad en sesiones futuras.
- **Metodología de Entrenamiento de InstructGPT:** Ise posgrados detalla los tres pasos del flujo de trabajo de InstructGPT: primero, realizar un ajuste fino supervisado (Supervised Fine-Tuning) utilizando datos de usuarios etiquetados por humanos; segundo, recolectar datos comparativos para crear un modelo de recompensa; y tercero, optimizar una política mediante el uso de aprendizaje por refuerzo con la técnica Proximal Policy Optimization (PPO).
- **Recursos y Datos para el Aprendizaje por Refuerzo:** Se mencionan bibliotecas como "Transformer Reinforcement Learning" de Hugging Face, que facilitan métodos como PPO y GRPO. Se aclara que el conjunto de datos de entrenamiento provino de las interacciones reales de los usuarios con la interfaz Playground de OpenAI, permitiendo que el modelo aprendiera a partir de preferencias humanas auténticas.
- **Resultados de InstructGPT y sus Beneficios:** Ise posgrados indica que los resultados de InstructGPT mostraron una reducción notable en las alucinaciones y una mejora en la calidad de respuesta en comparación con GPT-3. Se destaca que, aunque el ajuste fino supervisado ayudó a mitigar

alucinaciones, la implementación de aprendizaje por refuerzo fue crucial para alinear el modelo con las expectativas del usuario.

- **Adopción de InstructGPT y Aprendizaje por Refuerzo en Modelos Modernos:** Se analiza cómo el flujo de trabajo de InstructGPT y el aprendizaje por refuerzo se han convertido en un estándar en arquitecturas contemporáneas. Se cita a Llama 3 y DeepSeek R1, este último reconocido por utilizar la técnica GRPO, como ejemplos de la evolución y relevancia de estas metodologías de entrenamiento.
- **El Papel de los Evaluadores Humanos:** Se describe el proceso laborioso en el que los evaluadores humanos (labelers) calificaban las respuestas del modelo. Estos evaluadores utilizaban formularios para clasificar el contenido (como toxicidad o utilidad) y clasificaban diversos bloques de texto para entrenar los modelos de recompensa, una labor esencial para el entrenamiento supervisado.
- **Arquitectura Transformer y Visualización de Inferencia:** Se revisa la estructura de los modelos Transformer (decodificadores) y la tokenización mediante codificación por pares de bytes (BPE). LSE posgrados muestra una demostración de GPT-2 ejecutándose en el navegador, explicando que utiliza el formato ONNX para una inferencia eficiente en dispositivos con recursos limitados, permitiendo visualizar las matrices de atención de cada capa.
- **Mecanismos de muestreo y generación de texto:** LSE posgrados explicó el proceso de generación de tokens de un modelo GPT, donde la salida de los bloques de transformadores y la capa Softmax crean una distribución de probabilidad para el siguiente token ([01:58:38](#)). Se discutió cómo parámetros como la temperatura, el top-k y el top-p, que forman parte de algoritmos de muestreo externos al modelo, permiten ajustar la creatividad y el determinismo de la respuesta ([02:00:00](#)). Al configurar la temperatura en cero, el modelo se vuelve determinista, eligiendo siempre el token más probable, mientras que valores más altos aumentan la aleatoriedad ([02:01:27](#)).
- **Aclaración sobre estrategias de filtrado:** Anahi Bazet solicitó una aclaración sobre los algoritmos de muestreo, confirmando con LSE posgrados que el top-k selecciona los cinco tokens de mayor probabilidad, mientras que el top-p establece un umbral de probabilidad para filtrar los tokens candidatos ([02:04:24](#)).
- **Arquitectura del proyecto y uso de Onix:** Se presentó un proyecto interactivo basado en un archivo con formato Onix que permite visualizar las

capas de un modelo GPT-2 en un navegador ([02:04:24](#)). Onix funciona como una interfaz de programación de aplicaciones de alto nivel para plataformas de ejecución como unidades de procesamiento gráfico y central, soportando lenguajes como Python, C++, Java, Julia y Ruby, además de contar con soporte para dispositivos móviles ([02:06:00](#)).

- **Análisis del video sobre Apple Intelligence:** LSE posgrados destacó un video sobre la construcción de un modelo de lenguaje de 3 billones de parámetros por parte de ingenieros de Apple, el cual utiliza una arquitectura de transformador estándar y técnicas como aprendizaje por refuerzo con retroalimentación humana, diseñado para realizar inferencia local en computadoras Mac ([02:09:17](#)).
- **Detalles del primer trabajo práctico (TP1):** Se detalló el TP1 denominado Tiny GPT, disponible en versiones de inglés y español, el cual consiste en preentrenar un modelo de transformador pequeño, explorar algoritmos de decodificación y aplicar una variante de la red "feed-forward" llamada "Mixture of Experts" ([02:10:44](#)). La fecha de entrega está programada para la clase seis, antes de la clase siete ([02:12:13](#)) ([02:32:43](#)).
- **Tareas de implementación y comparación en el TP1:** Los estudiantes deberán crear un modelo denso equivalente a GPT-2 y luego modificarlo con la arquitectura "Mixture of Experts" (modelo denso vs. tipo DeepSeek/Mistral/Mixtral) ([02:13:40](#)). Las tareas incluyen la implementación de algoritmos de decodificación (codificación codiciosa, temperatura, top-k, top-p), medición de la técnica de optimización "KB Cache", visualización de mapas de atención, y el entrenamiento de un modelo denso utilizando el tokenizador de GPT-2 ([02:15:02](#)).
- **Recursos y optimizaciones para el entrenamiento:** El código proporcionado incluye varios asistentes ("helpers") y puede ejecutarse en Google Colab o computadoras con hardware modesto, como una MacBook M3 Pro con 18 gigabytes de memoria RAM ([02:18:16](#)). Se mencionaron técnicas de optimización opcionales, como la cuantización de 8 bits con la librería "bitsandbytes" y el uso de optimizadores cuantizados como Adam de 8 bits, para reducir el consumo de memoria durante el entrenamiento ([02:21:23](#)).
- **Evaluación de modelos y Mixture of Experts:** Los participantes deben evaluar el uso de los expertos en la arquitectura "Mixture of Experts", medir la utilización de los mismos y comparar el desempeño con modelos densos. Se planteó la posibilidad de investigar optimizaciones para acelerar el entrenamiento del modelo "Mixture of Experts", además de realizar una

evaluación opcional sobre la función de pérdida de balanceo de carga ([02:27:28](#)).

- **Instrucciones de entrega y repositorio:** Anahi Bazet y LSE posgrados acordaron que la entrega debe realizarse mediante un repositorio de GitHub, ya sea público o privado, enviando el enlace por correo electrónico al profesor ([02:30:25](#)). Los archivos pueden presentarse en una sola carpeta, aunque se utilicen varios archivos tipo notebook ([02:31:35](#)).
- **Panorama actual de modelos de lenguaje y costos:** LSE posgrados revisó el estado actual de modelos de lenguaje (Llama, Mistral, Gema, DeepSeek, ChatGPT) y el uso de plataformas de evaluación como "Arena leaderboard" ([02:34:06](#)). Se compararon costos de modelos para agentes, mencionando que Claude Opus es costoso, mientras que Sonnet y Haiku ofrecen alternativas más económicas para aplicaciones prácticas ([02:35:48](#)). Se destacó el modelo Qwen de 27 billones de parámetros por su rendimiento competitivo en tareas de programación ([02:37:18](#)).
- **Análisis de la arquitectura de Llama 1:** Se analizó la arquitectura de Llama 1 (13 billones de parámetros), que supera a GPT-3 utilizando una arquitectura de transformador codificador con mejoras como pre-normalización, función de activación SwiGLU y posiciones embebidas rotacionales ([02:38:38](#)). A pesar de ser más pequeño, el modelo demostró superioridad en métricas clave gracias a un entrenamiento con una gran cantidad de datos ([02:40:28](#)).
- **Evolución hacia Llama 2:** Llama 2 reutilizó la arquitectura de Llama 1 pero aumentó la cantidad de parámetros, los datos de entrenamiento y duplicó la longitud del contexto a 4000 tokens ([02:43:32](#)). Se incorporaron técnicas de ajuste fino supervisado y aprendizaje por refuerzo con retroalimentación humana para el modelo de chat ([02:44:54](#)).
- **Innovaciones de Mistral 7B:** Mistral 7B, lanzado a finales de 2023, introdujo mejoras como una ventana de contexto de 8192 tokens y el mecanismo de atención "sliding window attention", el cual permite procesar secuencias de manera más eficiente al focalizar la atención en una ventana de tamaño fijo ([02:46:45](#)).
- **Optimización de inferencia: KB Cache y atención:** Se explicó la técnica de "KB Cache" (Key-Value Cache), que evita recomputar las matrices de claves y valores para cada nuevo token, mejorando significativamente la velocidad de inferencia a costa de memoria ([02:51:42](#)). LSE posgrados describió el "Rolling Buffer Cache" de Mistral para evitar desbordamientos de memoria y la técnica "Grouped Query Attention" (atención de consulta

agrupada), utilizada en Llama 2 y otros modelos, para optimizar la atención mediante la compresión de las dimensiones de las matrices de claves y valores ([02:54:44](#)).

- **Diferencias en arquitecturas de modelos:** Ise posgrados explica que las variaciones principales entre las arquitecturas de modelos, fundamentadas en el Transformer Encoder, radican en el mecanismo de atención, el cual es señalado como el cuello de botella del sistema. Se establece que otros elementos que diferencian estas arquitecturas incluyen la longitud del contexto (context window), el número de parámetros, los conjuntos de datos (datasets), los codificadores posicionales (positional encodings) y la configuración de las capas ([02:57:49](#)).
- **Seguimiento administrativo y asignaciones:** Ise posgrados invita a los estudiantes a realizar preguntas adicionales a través de correo electrónico debido a la densidad del tema tratado. Se acuerda que el contenido de la clase anterior y el trabajo práctico (TP) serán publicados próximamente en una nueva rama (branch), y Ise posgrados enviará un correo electrónico para notificar a los estudiantes sobre esta actualización ([02:57:49](#)).
- **Cierre de la sesión:** La reunión finaliza con despedidas mutuas entre Ise posgrados, Belén Cattaneo, Sebastián Bonals, Martín González y Anahí Bazet, deseándose un buen descanso y una buena semana ([02:57:49](#)).

Revisa las notas de Gemini para asegurarte de que sean precisas. [Obtén sugerencias y descubre cómo Gemini toma notas](#)

*Cómo es la calidad de **estas notas específicas**? [Responde una breve encuesta](#) para darnos tu opinión; por ejemplo, cuán útiles te resultaron las notas.*